



Travaux pratique
Module : L'Analyse de Données
Filières : IRSI et Génie Informatique.
TP 5 (Sur l'Analyse en composantes principales)
Professeure : Labloul Bouchra

Exercice 1. *Une banque souhaite mieux comprendre le comportement de ses clients afin d'améliorer ses stratégies de segmentation marketing et de gestion de portefeuille. Pour cela, elle dispose d'une base de données contenant plusieurs variables financières et comportementales décrivant chaque client.*

Les variables étudiées sont les suivantes : le revenu annuel du client, le solde moyen de son compte bancaire, le nombre de transactions effectuées par mois, le montant moyen des transactions, l'âge du client ainsi que son taux d'endettement. Ces variables sont quantitatives et présentent des échelles différentes, ce qui rend leur analyse directe difficile.

En utilisant ce code pour créer le dataset :

```
import pandas as pd
np.random.seed(42)

data = pd.DataFrame({
    "revenu": np.random.normal(50000, 15000, 200),
    "solde": np.random.normal(20000, 10000, 200),
    "transactions": np.random.normal(80, 30, 200),
    "montant_moyen": np.random.normal(250, 80, 200),
    "age": np.random.normal(40, 12, 200),
    "endettement": np.random.normal(0.35, 0.1, 200)
})
```

1. *Quel est l'objectif principal de cette étude bancaire ?*
2. *Quelles sont les variables utilisées dans l'analyse ?*
3. *Pourquoi ces variables peuvent-elles poser un problème d'analyse directe ?*
4. *Quel type de données (qualitatif/quantitatif) est utilisé ici ?*
5. *Dans quel domaine réel peut-on appliquer ce type d'étude ?*
6. *Importer les bibliothèques Python nécessaires à l'analyse.*
7. *Vérifier la présence de valeurs manquantes.*
8. *Calculer les statistiques descriptives des variables.*
9. *Comment interpréter les corrélations entre variables ?*
10. *Pourquoi est-il important d'étudier les corrélations avant l'ACP ?*

11. Pourquoi doit-on standardiser les variables avant l'ACP ?
12. Quelle est la formule mathématique de la standardisation ?
13. Appliquer la standardisation sur le jeu de données avec Python.
14. Que se passe-t-il si on ne standardise pas les données ?
15. Quelle est la différence entre données brutes et données standardisées ?
16. Appliquer l'ACP sur les données standardisées.
17. Combien de composantes principales sont obtenues initialement ?
18. Que représente une composante principale ?
19. Comment interpréter les valeurs propres (eigenvalues) ?
20. Quelle est la signification de la variance expliquée ?
21. Tracer la courbe de variance cumulée.
22. Comment choisir le nombre optimal de composantes ?
23. Quel seuil de variance expliquée est généralement accepté ?
24. Combien de composantes conserve-t-on dans ce cas et pourquoi ?
25. Que représente une perte d'information dans ce contexte ?
26. Projeter les individus sur les deux premières composantes principales.
27. Que représente le plan factoriel ($PC1$, $PC2$) ?
28. Comment interpréter la position des individus sur le graphique ?
29. Peut-on identifier des groupes de clients ? Justifier.
30. Que signifie un individu éloigné de l'origine ?
31. Quelles variables contribuent le plus à $PC1$?
32. Quelles variables contribuent le plus à $PC2$?
33. Donner une interprétation métier de $PC1$.
34. Donner une interprétation métier de $PC2$.
35. Peut-on donner un nom à chaque composante ? Pourquoi ?
36. Quel est l'intérêt de l'ACP dans ce cas concret ?

Exercice 2. Une équipe de sportifs a été évaluée sur 5 tests physiques : Vitesse (V), Endurance (E), Force (F), Souplesse (S) et Coordination (C).

Athlète	V	E	F	S	C
$A1$	85	90	80	70	75
$A2$	70	60	75	85	80
$A3$	90	85	95	60	65
$A4$	60	70	65	90	85
$A5$	80	75	85	75	70

1. Centrer les données : soustraire la moyenne de chaque colonne.
2. Calculer la matrice de covariance des données centrées.
3. Calculer les valeurs propres et vecteurs propres de cette matrice.
4. Identifier les deux premières composantes principales et expliquer leur interprétation possible.
5. Projeter les données sur les deux premières composantes principales.

Exercice 3. On s'intéresse aux performances économiques de 6 pays européens.

Pour chacun, on observe plusieurs indicateurs macroéconomiques :

- X_1 : Taux de croissance du PIB (%)
- X_2 : Taux de chômage (%)
- X_3 : Inflation (%)
- X_4 : Balance commerciale (milliards dollars)

Le tableau ci-dessous présente les données standardisées (centrées-réduites).

TABLE 1 – Données standardisées

Pays	X_1	X_2	X_3	X_4
A	1.20	-0.80	0.50	1.10
B	0.90	-1.20	0.30	0.80
C	-0.20	0.60	-0.10	-0.30
D	-0.50	1.50	-0.30	-0.60
E	-1.10	0.90	-0.50	-0.80
F	-0.30	-0.10	0.20	-0.20

1. Vérifier que les variables sont bien centrées et réduites.
2. Construire la matrice de corrélation R .
3. Calculer les valeurs propres et les proportions de variance expliquée.
4. Déterminer le nombre de composantes principales à retenir selon :
 - le scree plot,
 - la variance cumulée.
5. Représenter les pays dans le plan (F_1, F_2) .
6. Identifier :
 - les pays les plus performants,
 - les pays en difficulté,
 - les profils intermédiaires.

Exercice 4. Nous analysons des indicateurs climatiques et environnementaux pour 10 pays. L'objectif est de réaliser une ACP afin d'identifier les axes principaux liés au changement climatique et à la capacité d'adaptation.

- Température moyenne annuelle (C°)
- CO_2 (tonnes)
- Émissions de méthane (kt)
- Déforestation annuelle (%)
- Énergies renouvelables (%)
- Indice de vulnérabilité climatique (0-1)

TABLE 2 – Données climatiques par pays

Pays	Temp (C°)	CO_2	CH_4	Déforestation	Renouvelables (%)	Vulnérabilité
P1	15.2	10.5	200	0.2	25	0.15
P2	22.5	7.0	180	0.5	20	0.25
P3	28.0	3.5	300	1.2	10	0.60
P4	19.0	6.0	150	0.3	30	0.20
P5	35.0	1.2	400	2.5	5	0.80
P6	16.5	8.0	220	0.1	40	0.10
P7	25.0	2.5	320	1.5	8	0.70
P8	12.0	12.0	100	0.0	35	0.05
P9	20.0	5.0	250	0.7	15	0.30
P10	30.0	1.0	380	2.0	3	0.85

1. Standardiser les données (centrer et réduire) afin de comparer des unités différentes.
2. Calculer la matrice de corrélation.
3. Réaliser l'ACP et calculer :
 - valeurs propres,
 - variance expliquée,
 - charges factorielles.
4. Tracer :
 - le scree plot,
 - le cercle des corrélations,
 - la projection des pays dans le plan $F_1 - F_2$.
5. Interpréter les axes principaux :
 - Axe F_1 : impact climatique,
 - Axe F_2 : capacité d'adaptation / transition énergétique.
6. Identifier les pays à fort impact climatique et ceux à forte capacité d'adaptation.

Exercice 5. Cet exercice vise à analyser des indicateurs hydrologiques et de qualité de l'eau pour 10 régions, afin d'identifier les axes principaux et comparer les régions selon leur niveau d'eau, débit, pollution et biodiversité.

TABLE 3 – Données hydrologiques et qualité de l'eau

Région	Niveau_Rivière	Débit_moyen	Pluviométrie	Température_eau	Pollution_N	Pollution_P	Biodiversité
R1	5.2	120	800	18.5	3.2	0.5	8
R2	4.8	90	700	20.0	4.0	0.7	6
R3	6.0	150	1200	16.0	2.0	0.3	9
R4	3.5	60	500	22.5	5.0	1.0	5
R5	2.8	40	400	25.0	6.0	1.5	4
R6	5.5	130	1000	17.0	2.5	0.4	8
R7	3.2	50	450	23.0	5.5	1.2	5
R8	6.2	160	1300	15.5	1.8	0.2	10
R9	4.0	70	600	21.0	4.5	0.8	6
R10	2.5	35	350	26.0	6.5	1.7	3

1. Standardiser les variables pour comparer des unités différentes.
2. Calculer la matrice de corrélation.
3. Réaliser l'ACP et calculer :
 - valeurs propres et variance expliquée,
 - charges factorielles des variables.
4. Tracer :
 - le scree plot,
 - le cercle des corrélations,
 - la projection des régions dans le plan F1-F2.
5. Interpréter les axes :
 - Axe F1 : caractéristiques hydrologiques (niveau, débit, pluviométrie)
 - Axe F2 : pollution et biodiversité
6. Identifier les régions avec :
 - fort débit et bonne qualité d'eau (R3, R8, R6),
 - vulnérables à la pollution (R5, R10, R7)
7. Calculer les contributions pour les régions extrêmes.